

Projet

Justine LOUARN - Lucie Raimbault - Marion Moussay

4/29/2022

Contents

Introduction	1
Importation des données	2
Première approche	3
Décomposition de la série	6
Modélisation par un processus auto-régressif	10
ACF et PACF	10
Analyse des résidus	12
Modèle de régression avec la décomposition de Fourier	15
Conclusion	16
Annexe	16
i. Fonction <i>decompose</i> : moyennes mobiles	16
ii. Méthode des différences	16
iii. <i>auto.arima()</i>	17

Introduction

La varicelle est une maladie infantile extrêmement contagieuse, elle est responsable d'une éruption de boutons. Elle guérit en une dizaine de jours. Dans cette étude nous allons nous intéresser au nombre de cas hebdomadiers de varicelle en Hongrie de 2005 à 2015. Nous avons choisis de nous intéresser seulement à la ville de Budapest, capitale et plus grande ville de Hongrie (1 752 286 habitants).

Dans ce projet nous avons pour objectif de déployer les outils vus en cours pour essayer d'ajuster un modèle aux données.

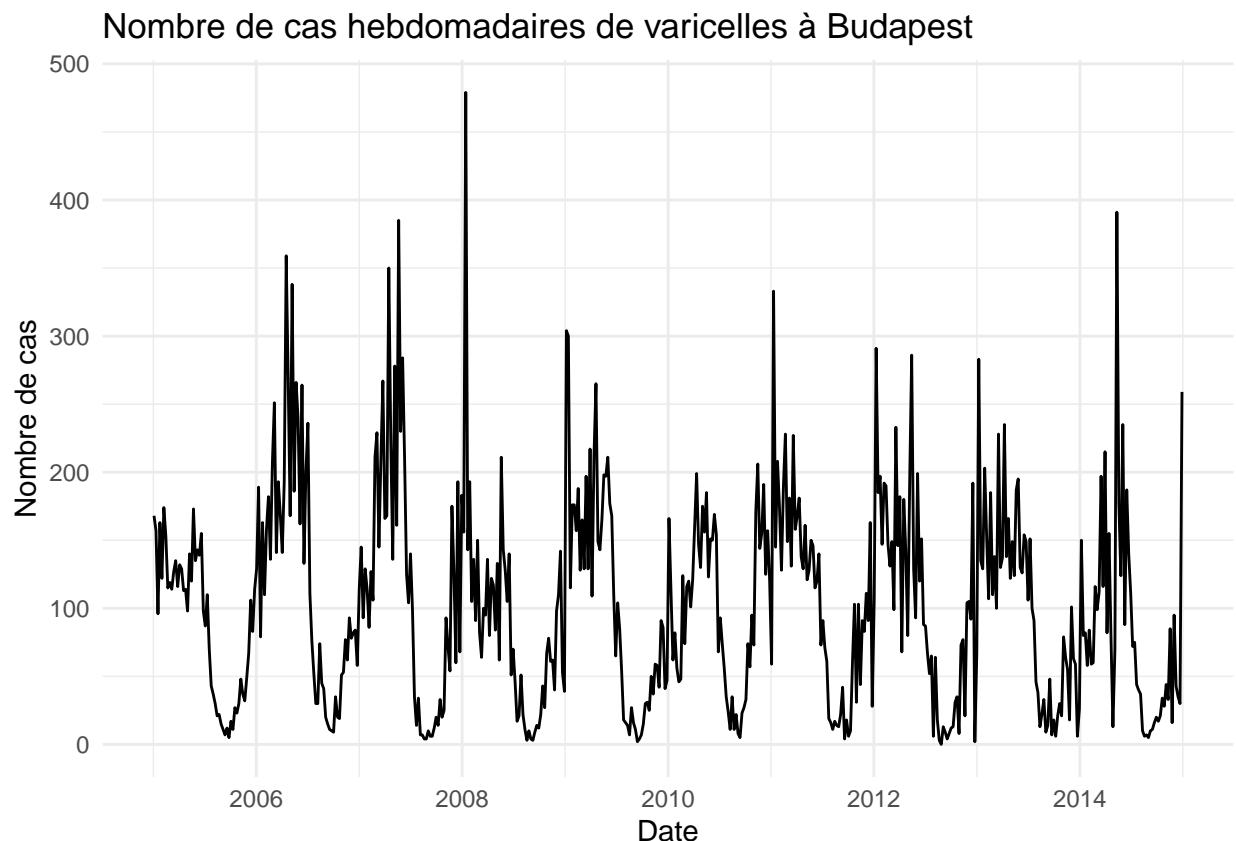
Dans un premier temps nous allons analyser notre série brutes puis nous allons déceler ou non une saisonnalité et une tendance, puis nous étudierons les résidus afin de créer un modèle qui s'ajuste à nos données.

Importation des données

```
data <- read.csv("hungary_chickenpox.csv")
data$date <- dmy(data$date)
mean(colMeans(data[-1]))  
  
## [1] 38.84282  
  
colMeans(data[-1])  
  
##    BUDAPEST    BARANYA      BACS      BEKES    BORSOD    CSONGRAD    FEJER      GYOR
## 101.24521  34.20498 37.16667 28.91188  57.08238  31.48851 33.27203 41.43678
##     HAJDU      HEVES     JASZ   KOMAROM    NOGRAD      PEST    SOMOGY  SZABOLCS
## 47.09770  29.69157 40.86973 25.64368  21.85057  86.10153 27.60920 29.85441
##     TOLNA      VAS  VESZPREM      ZALA
## 20.35249  22.46743 40.63602 19.87356
```

La moyenne générale des nombres cas de varicelles est de 38.84 de toutes les villes du jeu de données. La moyenne de Budapest est trois fois supérieure à la moyenne générale, ce qui semble tout à fait logique puisque c'est juste une question de proportion d'habitants par ville.

```
budapest <- data[,1:2]
colnames(budapest) <- c("date", "nb")
budapest %>% ggplot() + aes(x=date, y=nb) + geom_line() + ggtitle("Nombre de cas hebdomadaires de varicelle à Budapest")
```

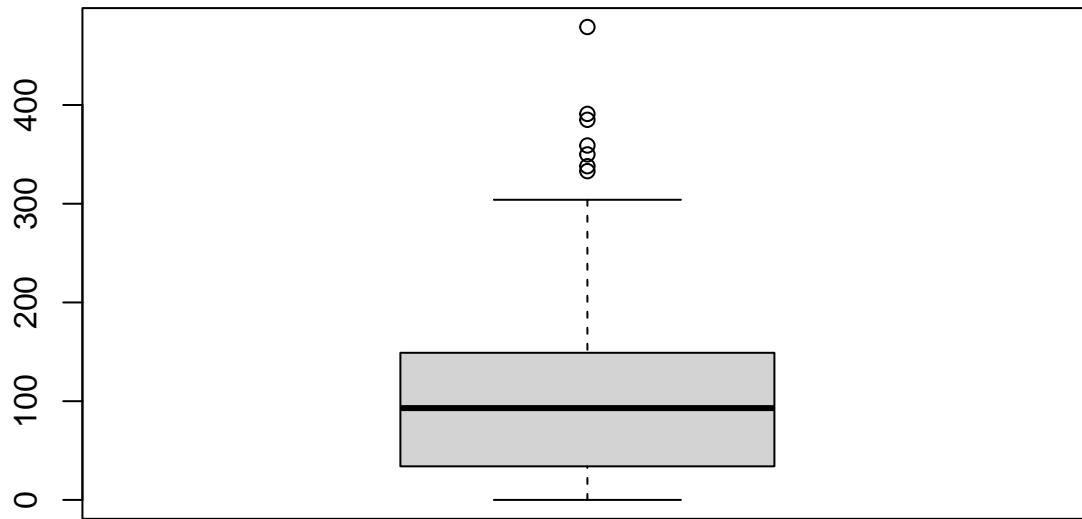


De cette première représentation, nous remarquons directement une forte saisonnalité d'un an, soit 52

semaines dans notre cas. Nous n'observons pas vraiment de tendance ou alors une légère décroissance mais cela reste difficile à dire avec ce graphique. De plus, on imagine un modèle additif puisque l'on voit une amplitude plutot constante.

```
boxplot(budapest$nb, main="Répartition des nombre de cas par quantiles pour la ville de Budapest")
```

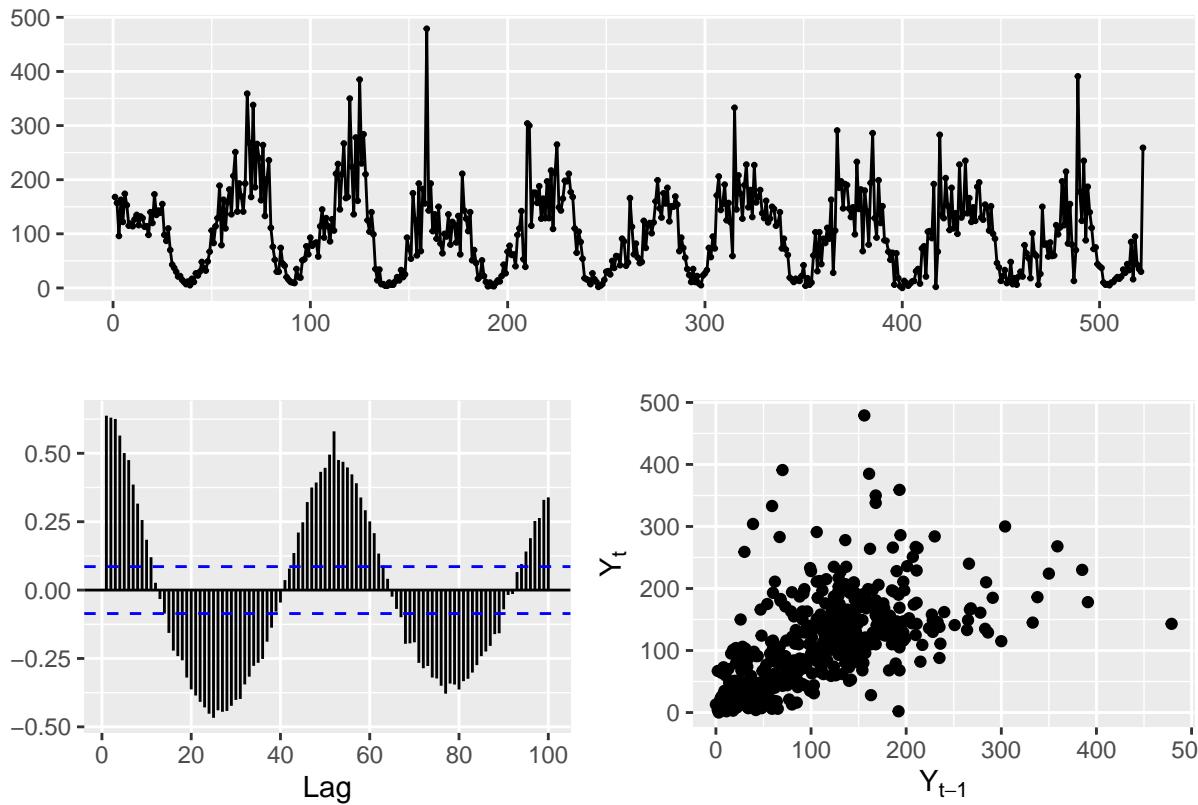
Répartition des nombre de cas par quantiles pour la ville de Budapest



Sur le boxplot des données hebdomadaires de varicelles à Budapest, on observe qu'il y a des données hautes, après vérification on ne les considère pas comme aberrantes. Les données étant très propre, nous n'avons pas eu de modifications à faire sur le jeu de données.

Première approche

```
budapest %>% select(nb) %>%
  ggtsdisplay(
    plot.type = "scatter",
    lag.max=100
  )
```



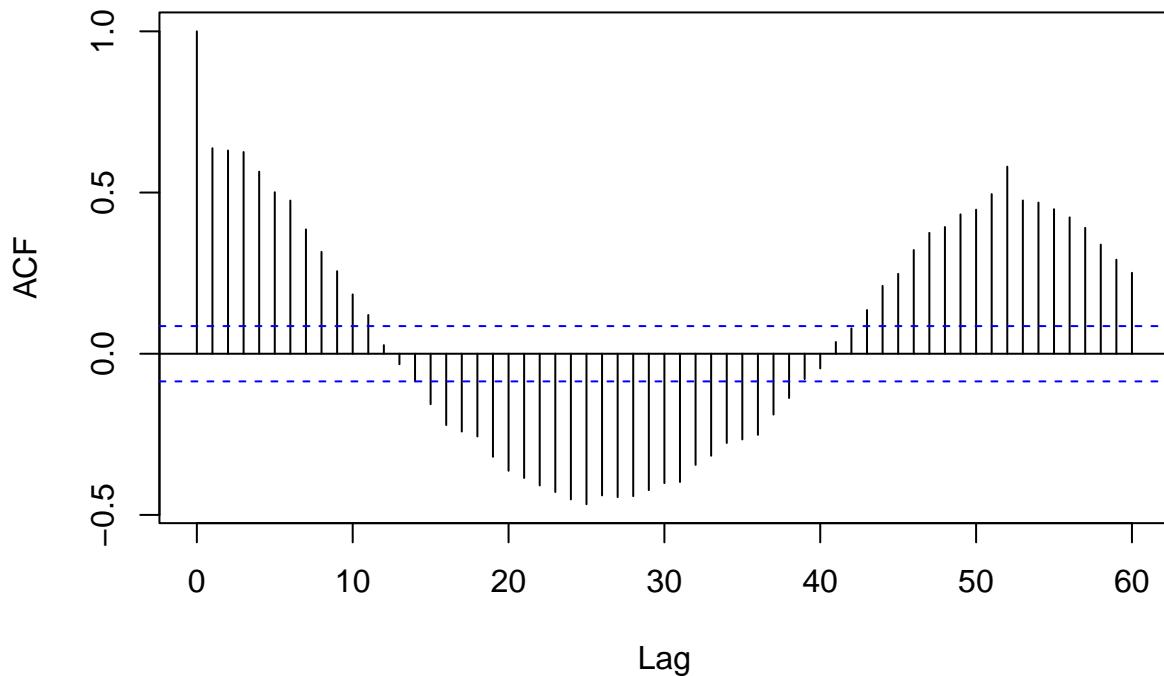
Pour mieux déterminer la saisonnalité nous allons observer la fonction d'autocorrélation. Elle semble périodique, ce qui indique une périodicité dans la série temporelle. La ligne pointillée bleue indique le niveau en-dessous duquel la corrélation n'est plus statistiquement significative.

Le nuage de point permet de visualiser l'auto-corrélation d'ordre 1, soit le quotient des covariances empiriques par la variance empirique. Plus le nuage de points est arrondis plus l'auto-corrélation est proche de 1. Ici on ne distingue rien de "remarquable".

Observons l'auto-corrélation de plus près :

```
acf(budapest$nb, lag.max = 60)
```

Series budapest\$nb

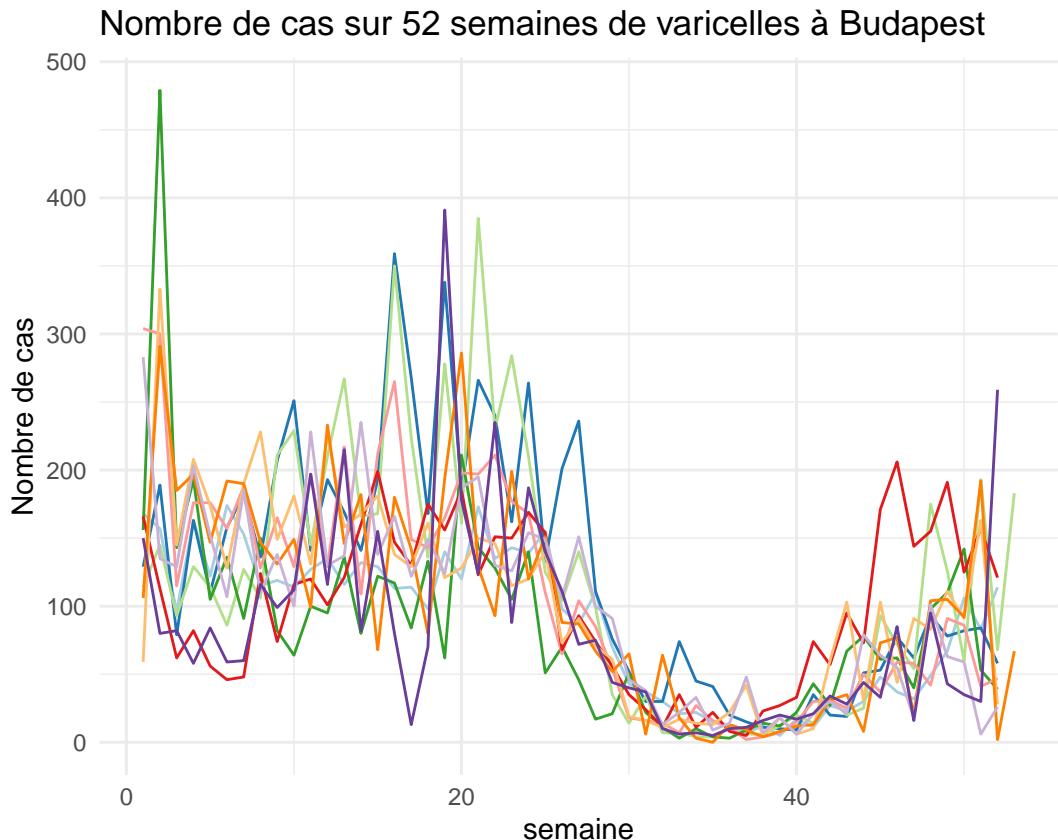


On voit ici que la périodicité est de 52 semaines. En effet chaque donnée est espacée de 7 jours. $T = 52$ semaines donc environ 12 mois, soit 1 an.

On regarde l'évolution pour chaque année.

```
budapest$annee<-factor(year(budapest$date))
budapest$semaine<-week(budapest$date)
```

```
ggplot(budapest,aes(x = semaine, y = nb,group=annee,colour=annee)) + geom_line() + scale_color_brewer(pal
```



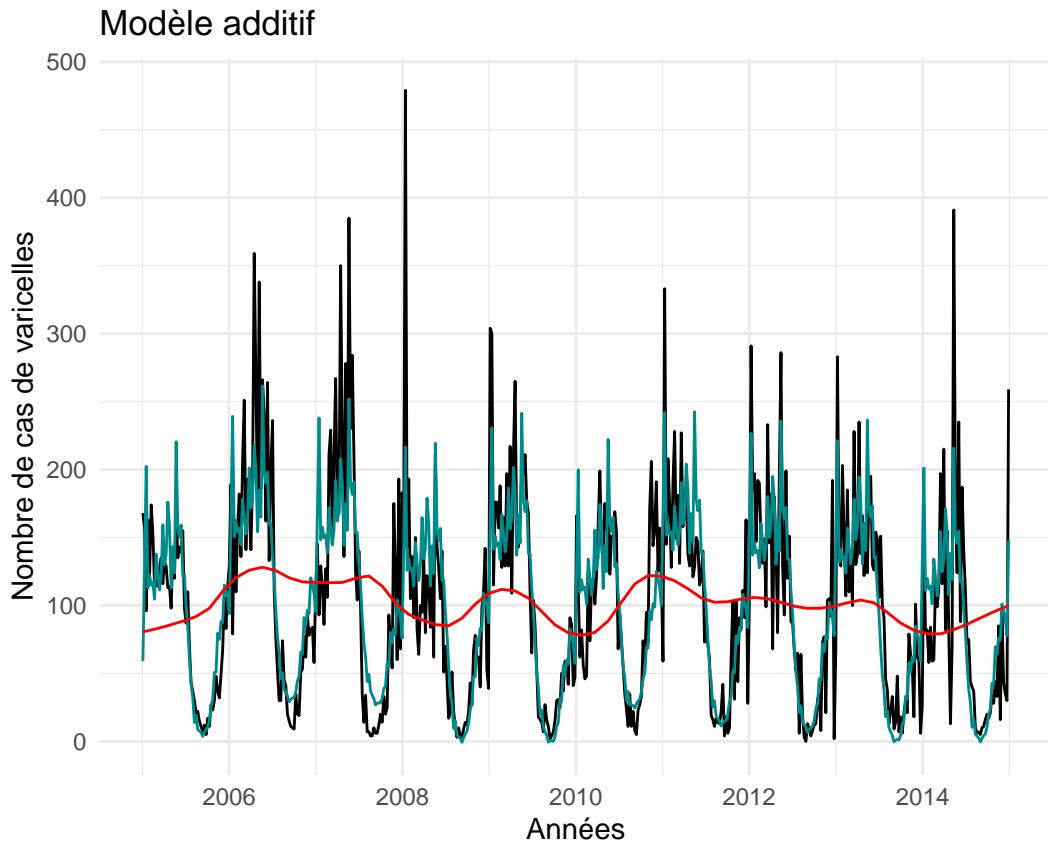
Avec cette représentation on observe bien la saisonnalité, le même schéma se reproduit tous les ans. On remarque qu'il y a plus de cas de varicelle au début de l'année (en hiver et au printemps). Durant l'été, il y a peu de cas de varicelles, puis à la fin de l'année le nombre de cas de varicelle augmente. Cela semble logique, d'après santé publique france, la varicelle est une maladie saisonnière, on observe chaque année une hausse des cas au printemps. Il s'agit d'une augmentation attendue de la maladie.

Décomposition de la série

```
temp.ts <- ts(budapest$nb, start=c(2005,1,3), frequency=52)
mod_stl_add <- stl(temp.ts, s.window = "periodic")

budapest_decomp <- cbind(budapest,as.data.frame(mod_stl_add$time.series))

budapest_decomp %>% ggplot() +
  geom_line(aes(x = date, y=nb, color="Xt")) +
  geom_line(aes(x=date, y=trend+seasonal, color="mt+st")) + geom_line(aes(x=date, y=trend, color="mt"))
  scale_color_manual(values = c("red", "cyan4", "black")) +
  theme(legend.position = c(0.8, 0.08), legend.direction = "horizontal") +
  labs(colour = "Modele") + ggtitle("Modèle additif") +
  xlab("Années") + ylab("Nombre de cas de varicelles") + theme_minimal()
```



Elimination de la saisonnalité

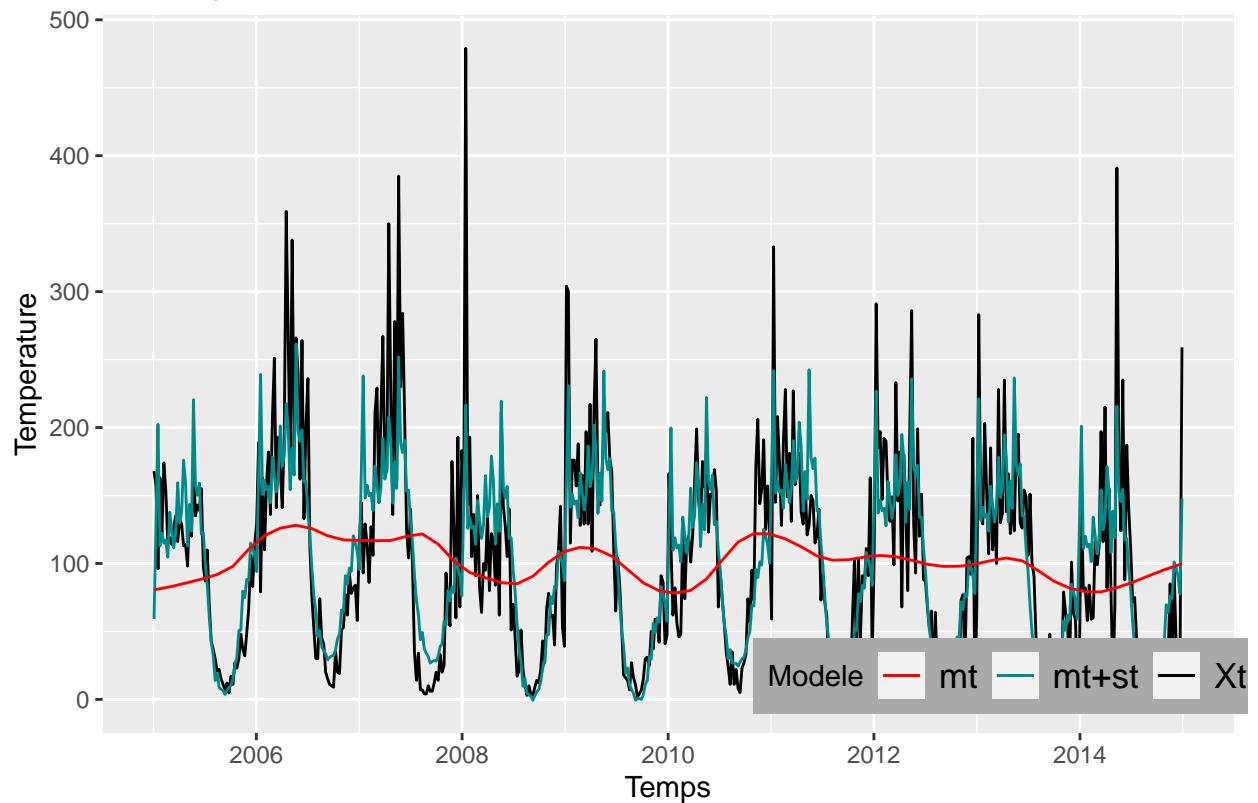
Puisqu'on a conclut qu'il n'y avait pas de tendance apparente, on utilise une différence de 1 uniquement dans un premier temps puis on inclut le lag en plus dans un second temps. On utilise la fonction *stl()* mais on aurait pu utiliser la méthode des différences ou la fonction *décompose* qui utilise le principe des moyennes mobiles. Ces deux méthodes sont illustrées dans l'annexe (i) et (ii).

```
temp.ts <- ts(budapest$nb, start=c(2005,03,01), frequency=52)
mod_stl_add <- stl(temp.ts, s.window = "periodic")

donnee <- cbind(budapest,as.data.frame(mod_stl_add$time.series))

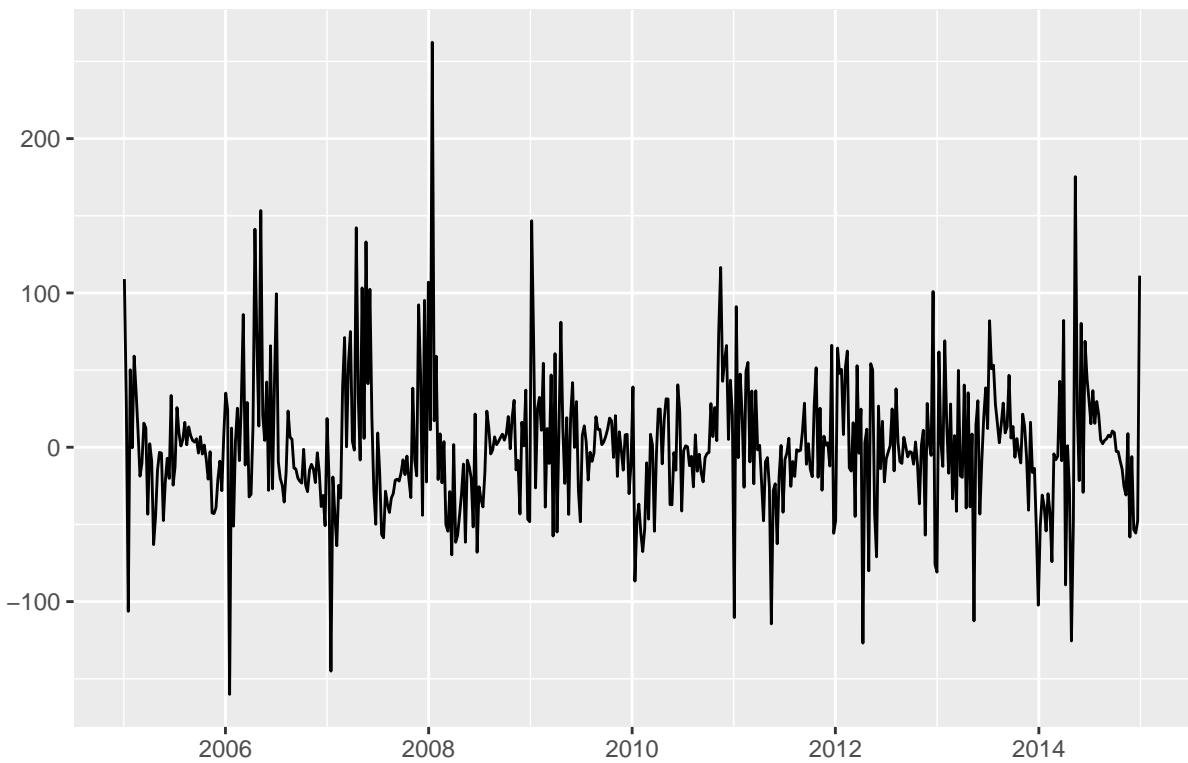
donnee %>% ggplot() +
  geom_line(aes(x = date, y=nb, color="Xt")) +
  geom_line(aes(x=date, y=trend+seasonal, color="mt+st")) + geom_line(aes(x=date, y=trend, color="mt"))
  scale_color_manual(values = c("red", "cyan4", "black")) +
  theme(legend.position = c(0.8, 0.08), legend.direction = "horizontal") +
  labs(colour = "Modele") + ggtitle("Décomposition du modèle additif") +
  xlab("Temps") + ylab("Temperature") +
  theme(
    legend.background = element_rect(fill = "darkgray"),
    legend.text = element_text(size = 13) #+ theme_economist()
  )
```

Décomposition du modèle additif



```
donnee %>% ggplot() + aes(x=date, remainder) + geom_line() + xlab("") + ylab("") + ggtitle("Résidus du")
```

Résidus du modèle

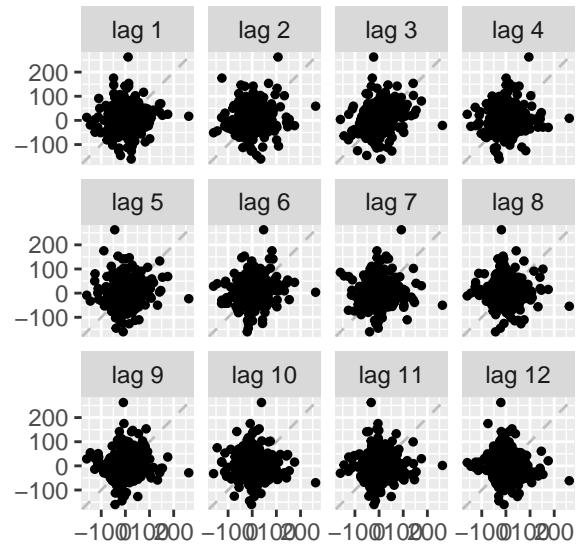
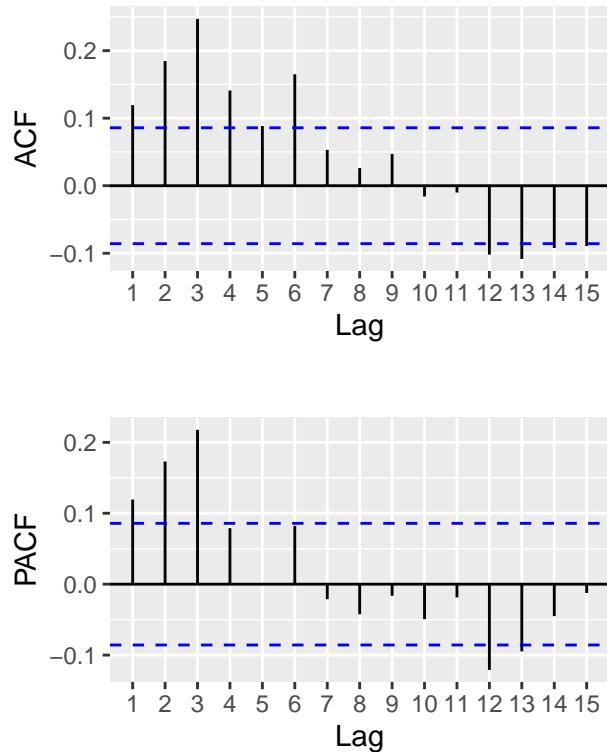


Les résidus sont bien centrés en 0.

```
p1 <- gglagplot(donnee$remainder, do.lines = FALSE, set.lags = 1:12, colour = FALSE)
p2 <- ggAcf(donnee$remainder, lag.max = 15) + ggtitle(" ")
p3 <- ggPacf(donnee$remainder, lag.max = 15) + ggtitle(" ")

grid.arrange(top = "Etude de nos résidus", p2,p3, p1, layout_matrix = rbind(c(1,3),c(2,3)))
```

Etude de nos résidus



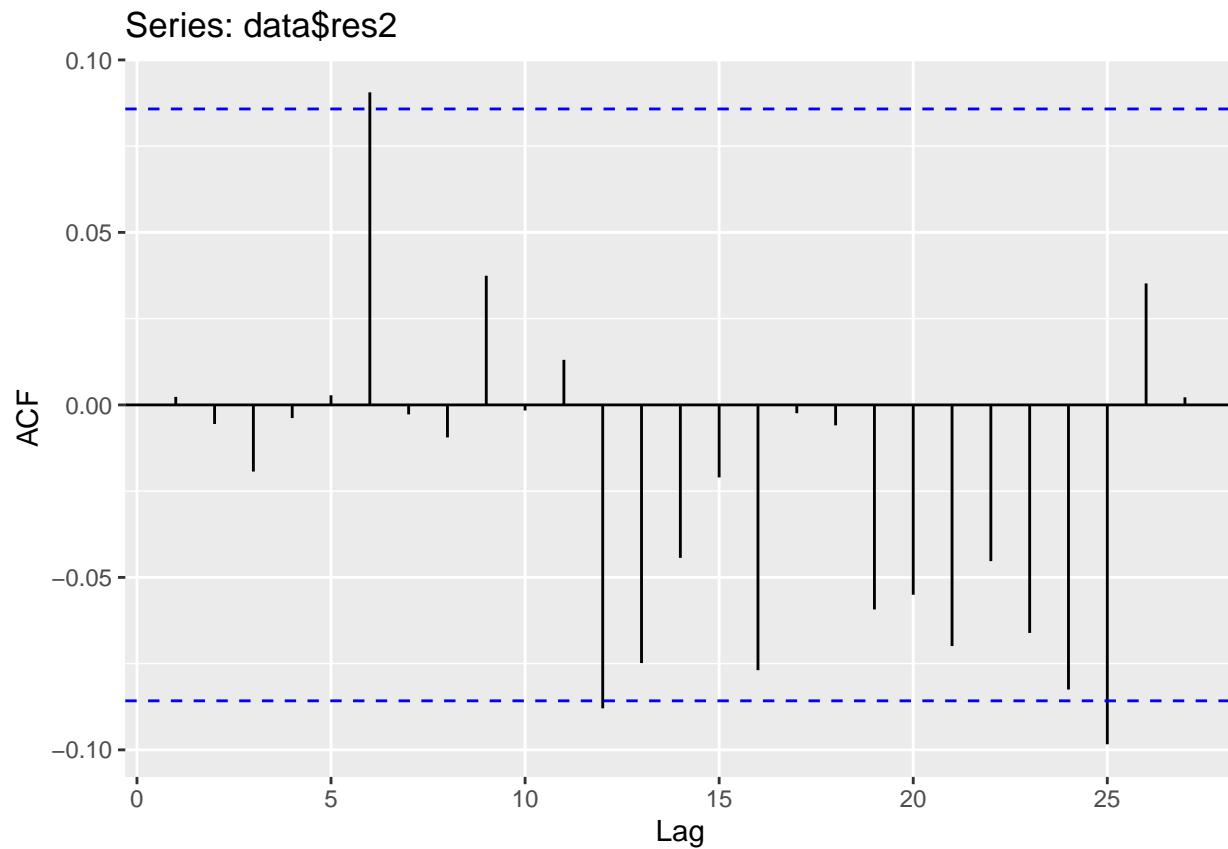
Sur la PACF, on observe une auto-corrélation nulle au lag 4. On choisirerait un processus auto-régressif de paramètre $p=4$: $AR(4)$. De plus, la fonction `auto.arima()` nous permet de conforter notre choix. Elle est disponible en annexe iii.

Modélisation par un processus auto-régressif

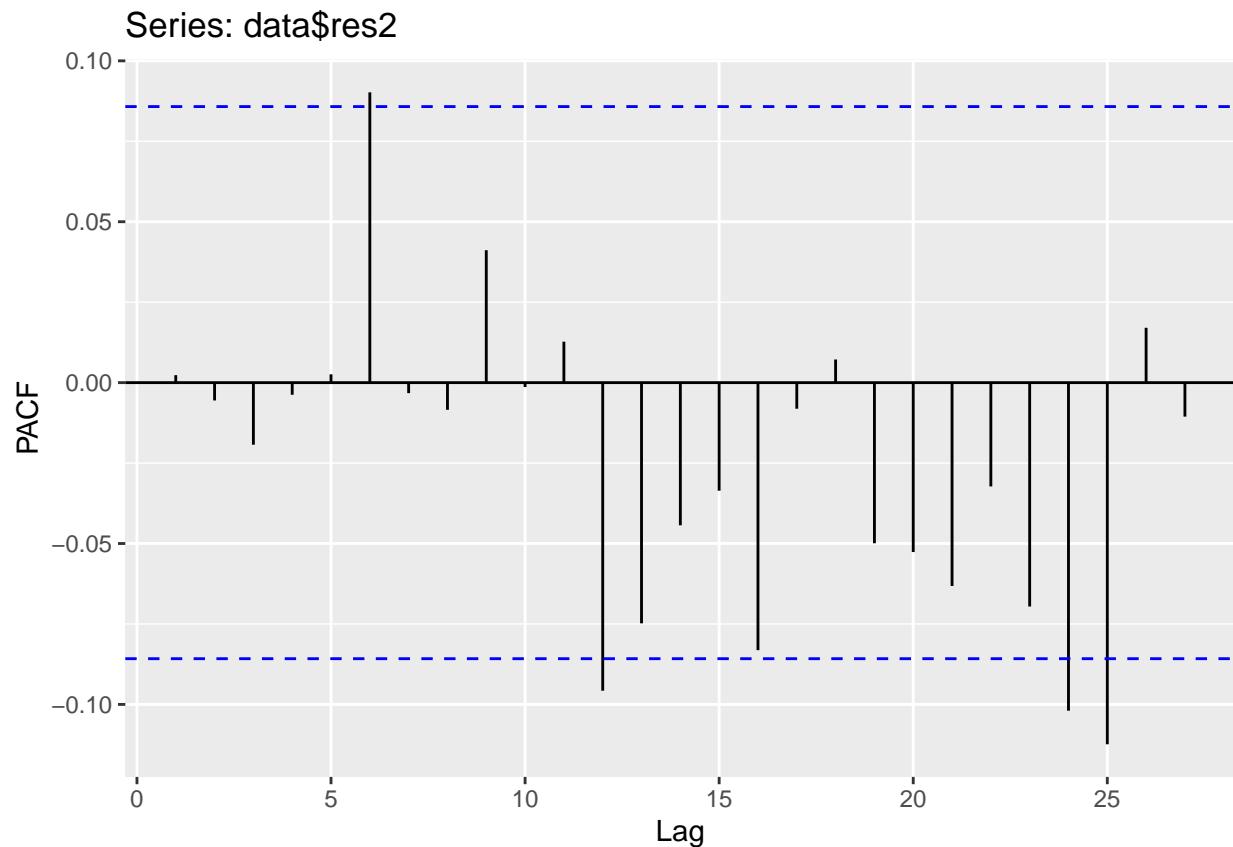
```
AR <- Arima(donnee$remainder, c(4,0,0))
data <- donnee %>% mutate(res2 = AR$residuals)
```

ACF et PACF

```
ggAcf(data$res2)
```



```
ggPacf(data$res2)
```

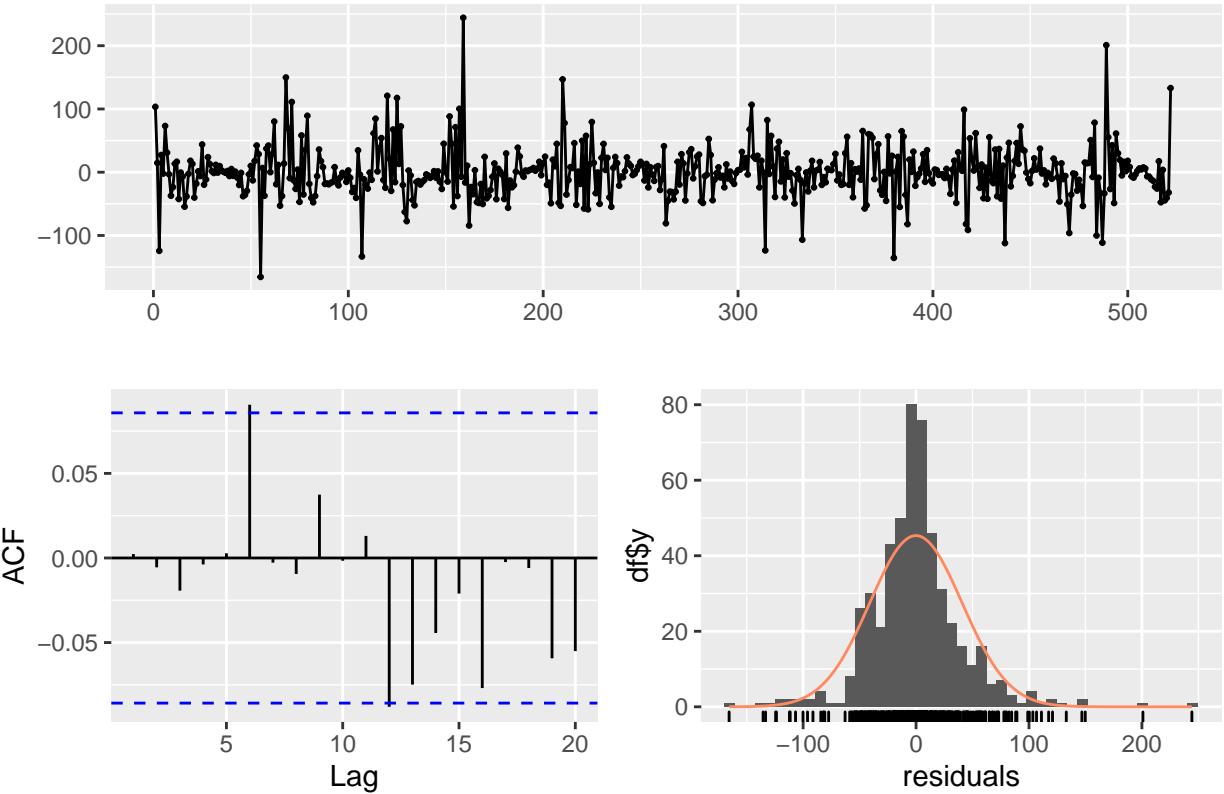


On remarque que l'ACF et la PACF sont similaires, ce qui reflète une absence d'effet résiduel.

Analyse des résidus

```
checkresiduals(AR, lag.max=20)
```

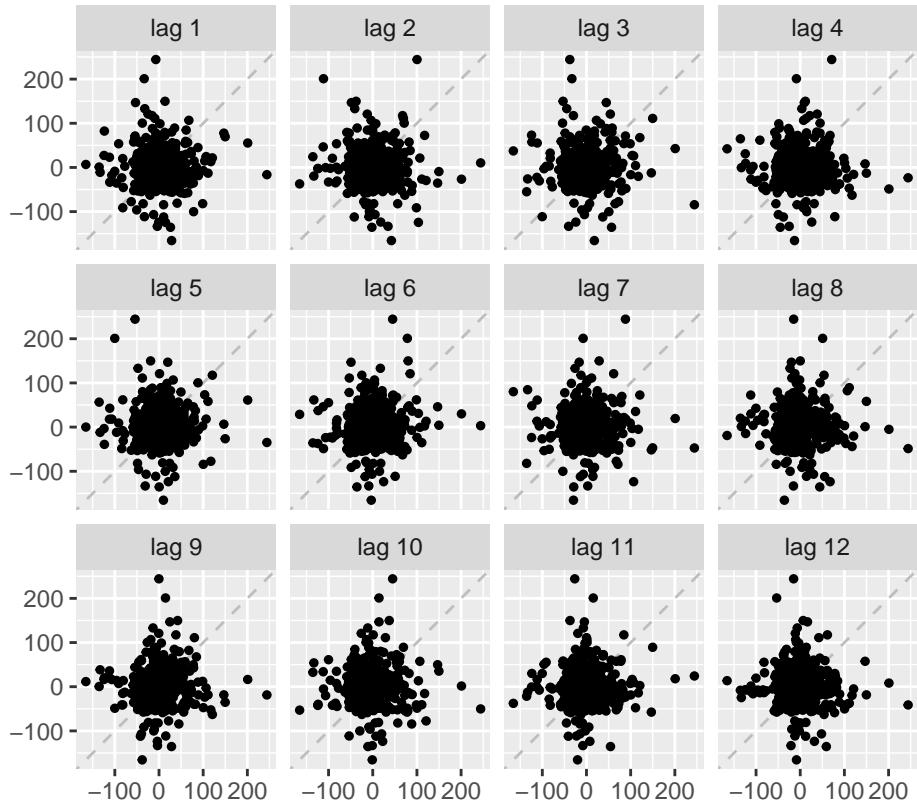
Residuals from ARIMA(4,0,0) with non-zero mean



```
##  
## Ljung-Box test  
##  
## data: Residuals from ARIMA(4,0,0) with non-zero mean  
## Q* = 5.3789, df = 5, p-value = 0.3714  
##  
## Model df: 5. Total lags used: 10
```

On ne perçoit pas de structure particulière sur l'ACF, de plus la densité des résidus semblent être gaussiennes.

```
gglagplot(AR$residuals, do.lines = FALSE, set.lags = 1:12, colour = FALSE)
```



Les résidus ne semblent pas corrélés, les nuages de points aux différents lags sont plutôt arrondis.

```
Box.test(data$res2, lag = 20, type = "Box-Pierce", fitdf = 2)
```

```
##  
## Box-Pierce test  
##  
## data: data$res2  
## X-squared = 20.127, df = 18, p-value = 0.3257
```

```
Box.test(data$res2, lag = 20, type = "Ljung-Box", fitdf = 2)
```

```
##  
## Box-Ljung test  
##  
## data: data$res2  
## X-squared = 20.708, df = 18, p-value = 0.2944
```

Les 2 tests de Box-Pierce et de Box-Ljung, renvoient une p-value > 5 %, alors on ne rejette pas l'hypothèse HO selon laquelle les auto-corrélations sont nulles. Les résidus sont décorréllés.

L'estimateur de la moyenne nous indique bien que les résidus sont centrés. De plus, l'estimateur de la variance nous montre une valeur de sigma étant de 1675.

```
mean(AR$residuals)
```

```
## [1] -0.09981575
```

```
var(AR$residuals)
```

```
## [1] 1675.004
```

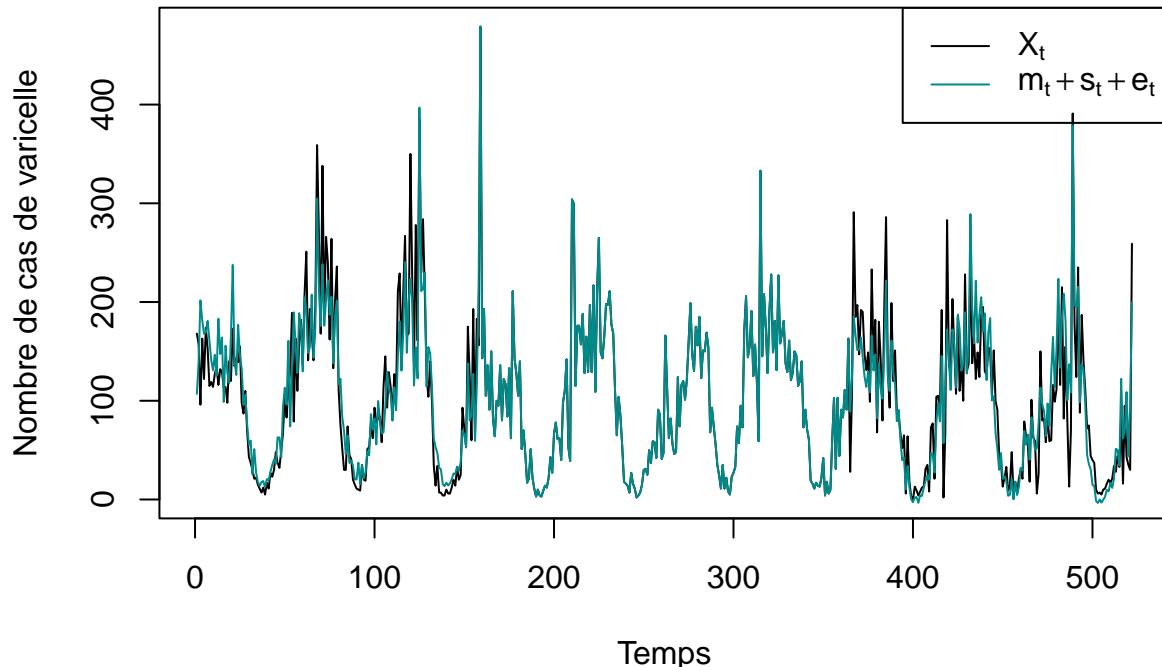
Modèle de régression avec la décomposition de Fourier

```
t <- 1:nrow(budapest)
st <- t%o%c(rep(1:182,2))*pi/182
st[,1:182] <- cos(st[,1:182])
st[,183:364] <- sin(st[,183:364])
names(st) <- c(paste("cos",1:182),paste("sin",1:182))
df <- data.frame(st, t, x=budapest$nb)

mod <- lm(data = df, x~. )

plot(budapest$nb,xlab='Temps',ylab="Nombre de cas de varicelle",main='Modèle', type = "l")
points(mod$fitted.values, type='l',col='cyan4')
legend('topright',c(expression(X[t]),expression(m[t]+s[t]+e[t])),col=c(1,"cyan4"),lty=1)
```

Modèle



On voit alors que le modèle que nous avons construit est en totale adéquation avec les données que nous avons.

Conclusion

Nous avons un modèle additif et un modèle AR(4) sur nos résidus.

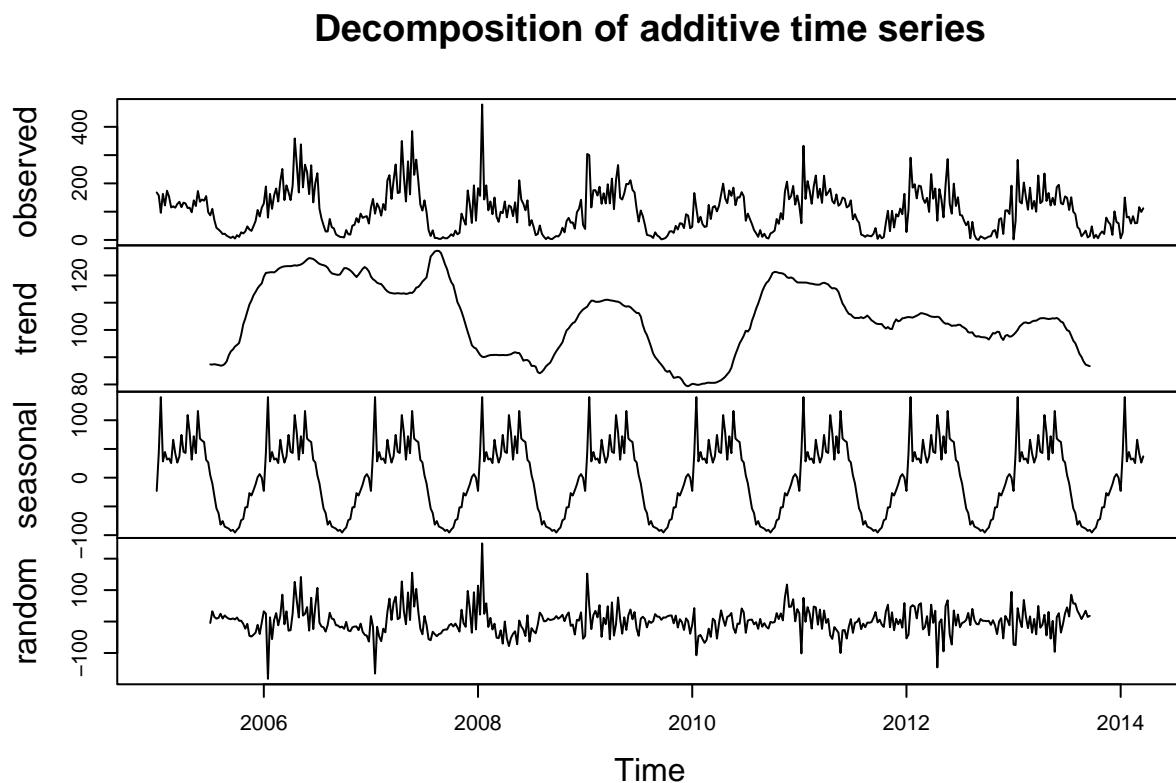
$$X_t = \hat{m}_t + \hat{s}_t + n_t + BB(\sigma^2 = 1675)$$
$$n_t = \hat{a}_1 n_{t-1} + \hat{a}_2 n_{t-2} + \hat{a}_3 n_{t-3} + \hat{a}_4 n_{t-4}$$

un AR(4).

Annexe

i. Fonction *decompose* : moyennes mobiles

```
budapest.ts <- ts(budapest$nb, start=c(2005,1,3), end =c(2014,12,29), frequency=52)
budapest_dec <- decompose(budapest.ts, type = "additive")
plot(budapest_dec)
```



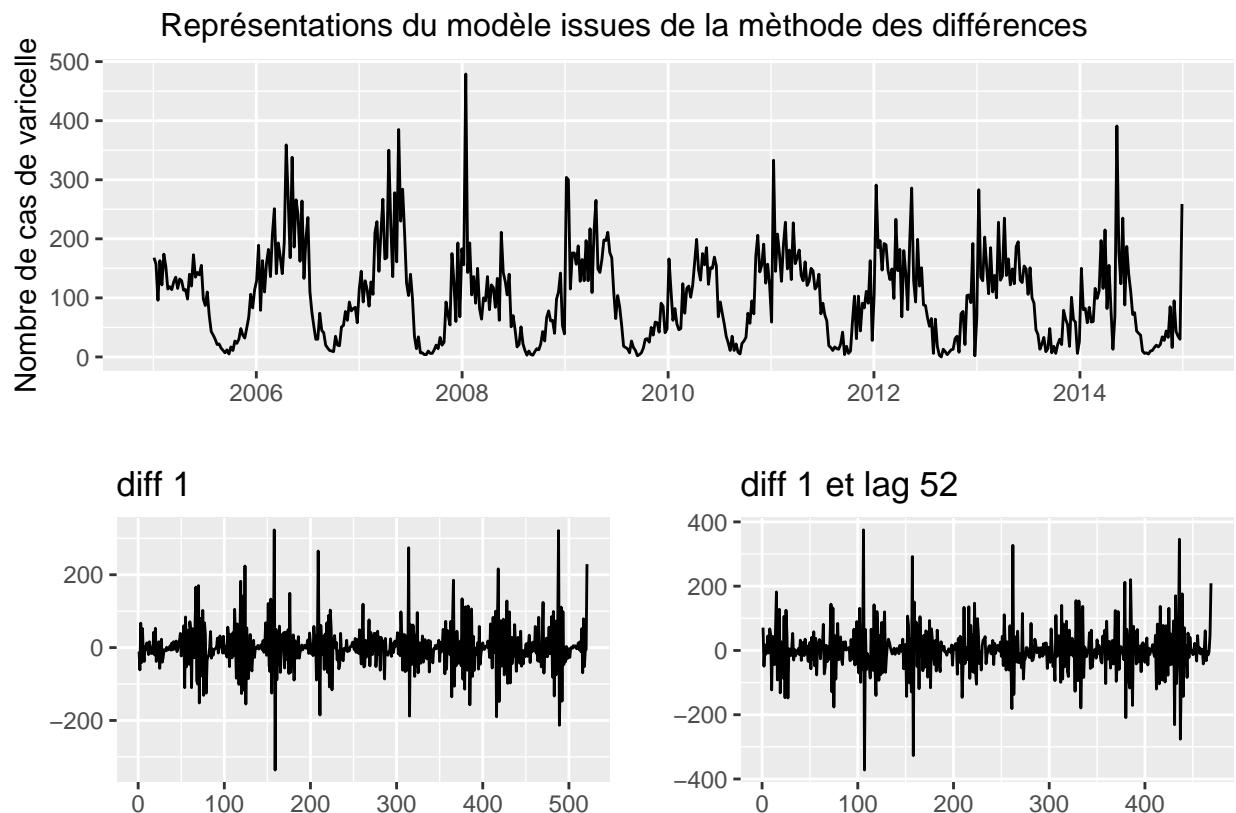
ii. Méthode des différences

```
T=52
```

```
xt_diff = diff(budapest$nb, differences = 1)
xt_diff_lag = diff(diff(budapest$nb, differences = 1), lag = T)

p1 <- donnee %>% ggplot() + aes(x=date, y=nb) + geom_line() + xlab("") + ylab("Nombre de cas de varicelle")
p2 <- ggplot() + aes(x=1:521, y=xt_diff) + geom_line() + xlab("") + ylab("") + ggtitle("diff 1")
p3 <- ggplot() + aes(x= 1:469, y=xt_diff_lag) + geom_line() + xlab("") + ylab("") + ggtitle("diff 1 et lag 52")

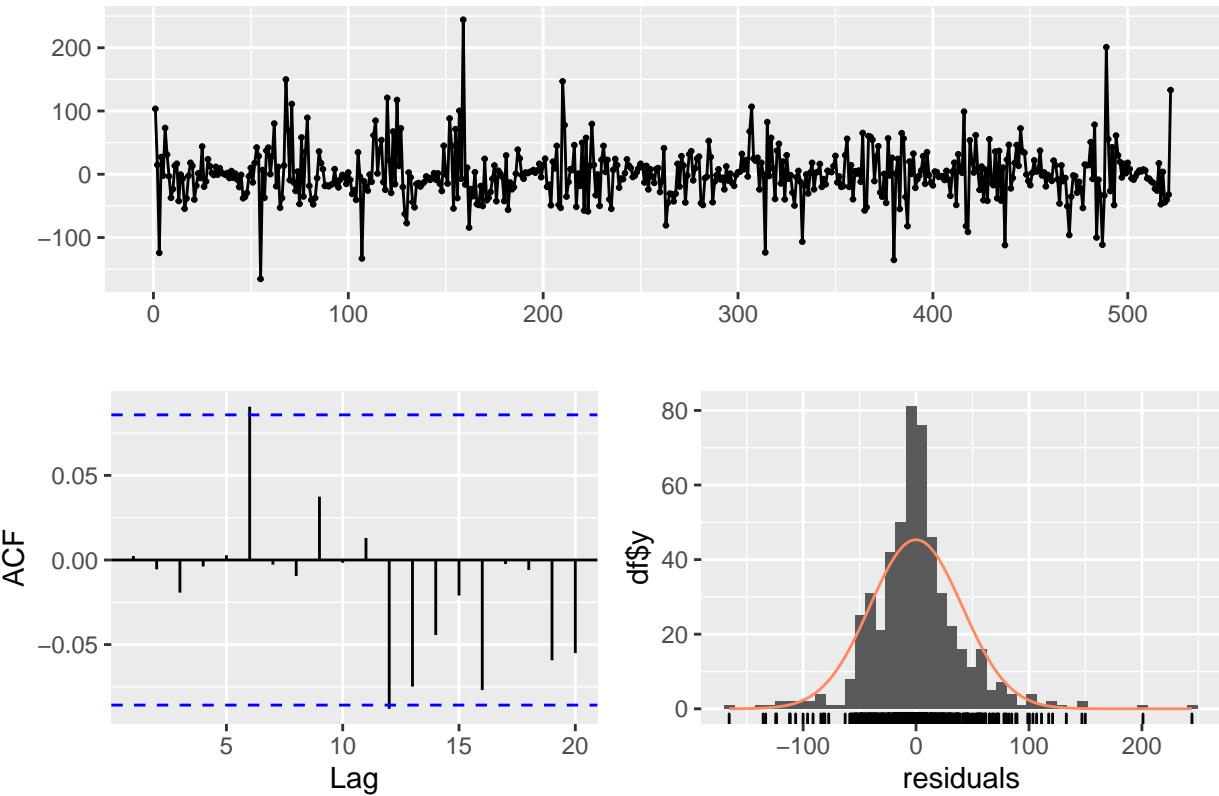
grid.arrange( top = "Représentations du modèle issues de la méthode des différences", p1, p2, p3, layout=
```



iii. auto.arima()

```
arima <- auto.arima(donnee$remainder)
checkresiduals(arima, lag.max=20)
```

Residuals from ARIMA(4,0,0) with zero mean



```
##  
## Ljung-Box test  
##  
## data: Residuals from ARIMA(4,0,0) with zero mean  
## Q* = 5.3789, df = 6, p-value = 0.4962  
##  
## Model df: 4. Total lags used: 10
```